ShiftLink 모델 발전 보고서

Oct 22, 2026 · @재영

1. 모델 계보: 첫 LLM부터 최종 모델까지

최종 모델은 **C5(ck176 + MES + 코드 규칙)**입니다. 9월의 범용 소형 모델(Qwen2.5-3B)에서 시작해, 카드를 고르는 판정기, 매뉴얼까지 읽는 RAG 모델, MES를 읽는 모델로 발전했습니다. 모든 모델은 Jetson(메모리 7.6 GB)에서 2.4~3B 크기, 4비트 양자화(Q4_K_M)로 돌아갑니다. 9/30 결정에 따라 외부 API는 쓰지 않습니다.

#	모델 (시기)	설명	특징	한계	이전 모델 대비 개선점
1	**Qwen2.5-3B Instruct** (플랜 B, 9/18~9/29)	범용 3B 모델. 검색한 지식 카드 5장을 받아 답을 쓴다	첫 Jetson 실측 모델. 카드 30장, 질문 20개	출력 상한이 없어 p95 194.5초(타임아웃 3건). 상한을 둔 뒤에도 인용 적중 9/20	기준선
2	Qwen2.5-3B-ko / ko-ft (9/29 비교 후보)	한국어 조정 공개 모델과 그 미세조정본	ko는 인용 10/20으로 비슷	ko-ft는 템플릿 누락으로 1/20. 9/30 삭제	개선 없음, 미채택
3	**EXAONE 3.5 2.4B Instruct** (플랜 C, 9/29~10/5)	LG의 한국어 2.4B 모델. 인용 개선 프롬프트 적용	인용 적중 13/20(Qwen 9/20), p50 5.7초. 10/1부터 후보 카드를 1장으로 줄임	모델이 직접 카드를 고르면 정답이 23/29로, 검색 1위(28/29)보다 못함. 답 문장 미충족 13/31	더 작은 모델로 인용 +4문항, 속도 개선. 이후 모든 모델의 기반
4	**exaone-sft-judge + E1** (10/6)	EXAONE을 LoRA로 학습한 판정기가 카드가 질문에 맞는지 0~3점으로 판정한다. 답은 카드 문장을 그대로 추출(E1)	"LLM은 판정, 답은 카드 근거 그대로". 지어낸 수치 0	카드에 없는 내용(매뉴얼·사건 기록)은 답하지 못함	답 문장 채점 충족 29 → 41(57문항 중), 미충족 26 → 10
5	**hybrid** (= exaone-sft-answer + 판정기 + 가드 v2, 10/7 시연 확정)	SFT 답변 모델이 카드로 문장을 쓰고, 가드에 걸리면 E1 추출로 대체	Jetson p50 4.4초, p95 5.6초. 거절 정확 (test30 17/19)	카드만 보므로 보류 셋 35문항 중 6문항만 답함. 매뉴얼·인계 기록 질문에 약함	추출형보다 자연스러운 답, 판정기로 안전성 유지

#	모델 (시기)	설명	특징	한계	이전 모델 대비 개선점
6	**RAG v2 + ck106** (exaone-rag-aug-ck106, 10/14)	카드·매뉴얼 PDF·인계 기록 3,951조각을 검색해, 근거 8조각을 읽고 답하도록 SFT(체크포인트 106)	근거 조각을 [S1]처럼 인용. 매뉴얼 페이지까지 답함	판정기 없이 쓰면 답 없는 질문도 답해 버림(거절 정확도 하락)	답할 수 있는 범위가 카드 → 카드+매뉴얼+사건 기록으로 확장
7	**S30h** (ck106 + 판정기 라우팅, 10/16 시연 전환)	판정기가 근거마다 P(점수≥2)를 매겨 0.3 미만은 버리고, 0.9 이상이면 답을 확정하고, 그 사이는 ck106이 판단(임계 0.3528)	보류 셋 답함 25/35(hybrid 6). 10/20 MES 이상 상태를 검색어에 반영, 근거의 수행 조건(R5) 표시	MES 값을 답에 쓰지 못함. 과거 인계 기록을 현재 상태처럼 말함(S3 상태 모순 12)	답할 수 있는 질문 4배 이상, 거절은 판정기로 유지
8	**ck176** (exaone-rag-mes-ck176, 10/21)	설비의 현재 MES 값·경보를 [MES] 블록으로 함께 읽도록 SFT	MES 값을 인용([M])하고 경보 유무를 구분	근거 없을 때도 MES로 답하게 하는 스위치(MES_ONLY)를 켜면 답 없는 지식 질문까지 답함(S2 44%)	S3 현재값 반영 0/42 → 42/42, 경보 구분 2/8 → 8/8, 상태 모순 12 → 0
9	ck186 (exaone-rag-mesv2-ck186, 10/21)	ck176과 같은 구조, v2 학습 데이터	지식 질문 거절이 조금 나음(S2 52%), p95 9.2초	사전 기준(현재값 ≥38/42, 경보 ≥7/8, 모순 0) 미달: 37/42, 4/8, 1	미채택
10	**C5 = ck176 + 코드 규칙** (10/22 최종 후보)	ck176에 MES_ONLY 끔 + MES 첫 줄(코드가 씀) + 관측값 없음·대상 설비 규칙 + 응급 조치 청크 분할	상태 질문은 거절해도 화면에 현재값 표시. 없는 값을 지어내거나 다른 설비 값을 섞지 않음	p95 10.5초, 메모리 최저 1,035 MiB로 장비 여유가 빠듯함. 답 있는 질문의 검색 실패는 남음	지식 질문 S2 44% → 60% 회복, 다른 설비 언급 18 → 0, 엎드린 자세 CPR 오답 해소

#1~#3은 범용 모델에 프롬프트만 바꾼 단계이고, #4부터는 우리 데이터로 LoRA를 학습한 모델입니다. #1~#5와 #6 이후는 평가 문항이 달라 수치를 직접 비교하지 않습니다. 같은 문항으로 잰 비교는 2절에 있습니다.

2. Jetson 배포 모델과 MES 모델의 성능

시연 장비(Jetson)에서 모든 단계를 같은 321문항, 같은 채점 규칙으로 다시 재습니다(10/21~22). 지표 정의는 측정 전에 고정했고, 단계는 현재 코드에서 그 구성을 켜서 재현했습니다. 모든 실행에서 오류는 0건입니다.

평가 문항

- **S1 봉인 60**: 답 있는 질문 36 + 답 없는 질문 24. 개발·조정에 한 번도 쓰지 않아 대표 숫자로 씁니다.
- **S2 개발 201**: 답 있음 128 + 답 없음 73. 모든 단계를 이 셋으로 맞춰 왔으므로 낙관적입니다.
- **S3 MES 충돌 60**: 30개 상황 × 질문 표현 2. MES에 일부러 이상값·경보·누락 신호를 넣고, 모델이 현재 상태를 읽는지 봅니다.
- **올바른 행동률** = (정답 근거를 인용해 답한 답 있는 질문 + 거절한 답 없는 질문) / 전체.
- **내용 정답률**(보조) = 봉인 셋의 문항별 채점 기준(꼭 들어갈 내용·들어가면 안 되는 내용)으로 답이 실제로 맞았는지. 단계 이름을 가린 채점자 2명의 일치도는 카파 0.87입니다.

단계별 결과

단계	구성	S1 올바른 행동	S1 내용 정답	S2 올바른 행동	S3 현재값 반영 (/42)	S3 경보 구분 (/8)	S3 상태 모순	p95 (초)	최저 여유 메모리 (MiB)
C1	hybrid (10/7 시연)	45%	37%	61%	6	0	1	7.4	1,299
C2	RAG v2 + ck106, 판정기 없음	52%	50~55%	57%	0	0	3	7.7	1,303
C3	S30h (10/16 시연)	50%	53%	63%	0	2	12	9.0	1,163
C4	S30h + ck176 + MES	48%	58~60%	44%	**42**	**8**	**0**	10.4	1,138
C4b	S30h + ck186 + MES	50%	52~53%	52%	37	4	1	9.2	1,300
C4c	C4 + MES_ONLY 끔	50%	58~60%	59%	30	7	0	10.3	1,165
C5	C4c + MES 첫 줄 + 코드 규칙 + 청크 분할	48%	(C4c와 같은 모델 답)	**60%**	30 (화면 표시 **42**)	7	**0**	10.5	1,035

- 내용 정답의 범위는 채점자 2명의 값입니다.
- C5의 "화면 표시 42"는 거절한 답에도 코드가 MES 첫 줄(예: "현재 MES(RT-02): 클램프 압력 90 bar 낮음")을 붙여, 작업자가 현재값을 보는 행 수입니다(탐색 지표).
- 기준(10/15): p95 10초 이하, 여유 메모리 1.0 GiB 이상. C4 이후는 경계에 걸려 있습니다.

RAGAS (S3 273건, 세 채점자)

RAGAS식 채점은 단계 이름을 가리고 섞은 시트로 했습니다. faithfulness는 답의 주장 중 근거(주어진 문서·MES)로 뒷받침되는 비율, relevancy는 질문에 맞게 답했는지(1~5점을 0~1로)입니다.

단계	faithfulness 사람 / Codex / Claude	relevancy 사람 / Codex / Claude
C1 hybrid	0.76 / 0.81 / 0.75	0.45 / 0.67 / 0.41
C2 RAG v2 + ck106	0.82 / 0.88 / 0.94	0.47 / 0.65 / 0.36
C3 S30h	0.84 / 0.89 / 0.99	0.51 / 0.61 / 0.32
C4 ck176 + MES	**0.86** / 0.85 / 0.93	**0.84** / 0.88 / 0.84
C4b ck186 + MES	0.90 / 0.92 / 0.95	0.85 / 0.86 / 0.84

- relevancy는 세 채점자 모두 MES 단계(0.84~0.88)가 이전 단계(0.32~0.67)보다 확실히 높습니다.
- faithfulness는 사람과 Codex가 잘 맞고(상관 0.80), Claude와는 약합니다(0.43). 사람 기준으로는 MES 단계가 조금 더 높습니다.
- 채점자 간 relevancy 가중 카파는 0.70~0.79입니다.

안전 오답 추적

항목	이전	C5
감전 환자 CPR을 "엎드려 눕히고 흉부압박"(NQ-D14)	C4에서 발생. 원인은 흉부압박과 니엘센법이 한 청크에 붙어 있던 것	없음. 응급조치 지침을 방법 제목 단위로 다시 나눔
MES에 값이 없는 신호(베어링 온도·공압)를 다른 값으로 채워 "정상"	ck176·ck186 모두 4건	0건. "유효한 측정값이 없습니다. 현장 계기로 확인"
질문에 없는 설비의 MES를 섞어 답함(예: RT-03 질문에 RT-02 값)	C4 답변 288건 중 18건	0건
과거 인계 기록을 현재 상태처럼 말함(상태 모순)	C3 12건	0건

3. 정리

최초 시연 모델(hybrid)에서 C5로 오면서, 가장 크게 달라진 것은 **MES를 읽고 답하는 능력**입니다. 지식 질문 정확도는 내용 기준으로 37%에서 58~60%로 올랐고, 안전 오답은 추적한 네 유형 모두 0건입니다.

수치로 본 개선 (C1 hybrid → C5)

지표	C1 hybrid	C3 S30h	C5 최종
S3 현재값이 작업자에게 보인 상황 (/42)	6	0	**42**
S3 경보 구분 (/8)	0	2	**7**
S3 상태 모순	1	12	**0**
S1 내용 정답률	37%	53%	**58~60%** (C4c 기준)
S2 올바른 행동률	61%	63%	60%
RAGAS relevancy (사람)	0.45	0.51	**0.84** (C4)
RAGAS faithfulness (사람)	0.76	0.84	**0.86** (C4)
p95 응답 시간	7.4초	9.0초	10.5초

- 답할 수 있는 범위도 넓어졌습니다. 보류 셋(35문항)에서 hybrid는 6문항, S30h는 25문항에 답했습니다.
- 대가는 속도와 메모리입니다. p95가 3초 늘고 여유 메모리가 1,299 → 1,035 MiB로 줄어, 장비 기준의 경계에 있습니다.
- 봉인 셋(S1)의 올바른 행동률은 45~52%에서 크게 움직이지 않았습니다. 오답의 절반 이상(17/30)이 검색이 정답 근거를 못 가져온 경우라, 모델보다 검색의 한계입니다.

실사용에서 달라진 점

1. **근거의 폭**: 카드만 보던 답이 매뉴얼 PDF·안전 지침·인계 기록까지 읽고, 출처(문서명·쪽, 인계 기록)를 답 끝에 붙입니다.
2. **현재 상태 읽기**: "클램프 압력 지금 어때요?"에 "현재 MES(RT-02): 클램프 압력 90 bar 낮음(기준 95–115), 활성 경보 없음"처럼 값과 기준을 바로 보여 줍니다. "경보 떴다는데"라는 말과 실제 MES 경보가 다르면 그 차이를 말합니다.
3. **과거와 현재 구분**: 인계 기록의 예전 값을 지금 상태처럼 말하던 오류(상태 모순 12건)가 없어졌습니다.
4. **모르면 모른다고 하기**: MES에 값이 없는 신호는 "유효한 측정값이 없습니다. 현장 계기로 확인하세요"라고 답합니다.
5. **설비 혼동 방지**: "GR-02", "출측 감속기"처럼 다른 설비를 물으면 그 설비를 기준으로 답하고, 선택한 설비의 현재값을 섞지 않습니다.
6. **응급조치 오답 제거**: 감전 환자 CPR 질문에 바로 눕힌 자세의 흉부압박 30:2만 안내합니다.

왜 C5를 최종 모델로 골랐나

후보	탈락 이유
C3 S30h	MES 값을 답에 쓰지 못하고(현재값 0/42), 과거를 현재처럼 말함(모순 12)
C4 ck176 + MES	MES는 만점이지만 답 없는 지식 질문에도 MES로 답해 S2 44%
C4b ck186 + MES	결과를 보기 전에 정한 기준(현재값 ≥38, 경보 ≥7, 모순 0)에 미달
C4g C4 + 코드 규칙	안전은 좋아졌지만 지식 지표가 C4와 같음(S2 44%)

C5는 이 중 유일하게 세 가지를 함께 만족합니다. 지식 질문은 S30h 수준(S2 60%, 내용 정답 58~60%)을 지키고, 상태 질문에는 현재값 42/42를 보여 주며, 추적한 안전 오답이 모두 0건입니다. 모델이 틀리기 쉬운 부분(없는 값, 다른 설비, MES 요약)은 모델에 맡기지 않고 코드가 정해진 문장으로 처리하므로, 같은 질문에 항상 같은 답이 나옵니다.

배포 상태(10/22 12:57): 코드 규칙은 PR #330으로 main에 병합됐고, Jetson 시연 장비에 C5 구성과 응급조치 분할 색인을 적용해 서비스가 C5로 동작 중입니다. 되돌리기는 `~/rag2_tmp/c5_install/rollback.sh` 입니다.

C5 한눈에 보기

답변 모델	판정기	검색	MES 처리	코드 규칙	S1 올바른 행동	S1 내용 정답	S2 올바른 행동	S3 현재값 (/42)	S3 경보 구분 (/8)	S3 상태 모순	안전 오답	p95	최저 여유 메모리
exaone-rag-mes-ck176 (EXAONE 3.5 2.4B + LoRA, Q4_K_M)	exaone-sft-judge: 근거별 P(≥2) 0.3 미만 버림 · 0.9 이상 답 확정 · 그 사이 임계 0.3528	embeddinggemma 300M(CPU), 근거 최대 8조각, 응급조치 분할 색인	[MES] 블록 입력 + 코드가 쓰는 MES 첫 줄, MES_ONLY 끔	관측값 없음 · 대상 설비	48%	58~60%	60%	30 (화면 42)	7	0	0건	10.5초	1,035 MiB

측정: Jetson, 321문항, 2026-10-22, 오류 0. S1 내용 정답은 모델 답이 같은 C4c의 채점값입니다. 정상 범위 규칙(PR #330)을 더하면 계산상 S1 1문항(NQ-D08)이 더 맞습니다.