ShiftLink 프로젝트 결과보고서

현장 노하우 기반 온디바이스 MES 보조 에이전트

- **GitHub 저장소:** https://github.com/hyjuy/ShiftLink

> **과정:** 온디바이스 AI 기반 산업용 소프트웨어 개발 1기 **팀:** ShiftLink | 유현준(팀장), 최재영, 허재원, 전혜민
>
> **작성일:** 2026-10-23

---

1 요약

ShiftLink는 설비별 작업 노하우와 조치 이력을 지식으로 정리하고, 작업자가 필요한 정보를 현장에서 조회해 다음 교대에 전달하도록 만든 온디바이스 MES 보조 에이전트다. Unity 가상 공장의 설비를 PDA로 촬영하면 라즈베리파이에서 설비를 분류하고, Jetson에서 관련 지식을 검색해 근거와 함께 답변한다. 작업자는 MES 현재값을 참고하고 조치·근무일지·인계 기록을 남길 수 있다.

설비 인식, 원문 RAG, MES 현재값을 연동한 최종 답변 파이프라인(C5), 기록 저장·클라우드 업로드 및 지식카드 관리 흐름을 구현했다. 321문항 비교에서는 현재값 표시와 추적한 오류 유형이 개선됐지만, 봉인 셋(S1)의 올바른 행동률은 48%로 검색·근거 품질의 한계가 남았다. 운영 온톨로지는 별도 합성 MES 시제품으로 검증했다. 본 프로젝트는 교육·시뮬레이션용 MVP다.

2 시스템 구성

Unity 작업자 시점 영상 → PDA 촬영 → Pi CNN 설비 분류 → Jetson MES·지식 검색·판정·답변 → PDA 근거 확인 → 조치·인계 저장 → Aiven 업로드

구분	내용
하드웨어	Jetson Orin Nano 8GB, 라즈베리파이 4 PDA, Unity 실행 PC, 얼굴 로그인용 USB 웹캠
설비 인식	MobileNetV3-Small 6클래스 FP32, Pi ONNX Runtime CPU 추론
검색과 답변	`embeddinggemma` 검색, `exaone-sft-judge` 판정, `S30h` 답변 경로. 10/22 운영 기록의 답변 모델은 `exaone-rag-mes-ck176:latest`
소프트웨어	Python 기반 MES·PDA 서비스, Unity 가상 공장, 브라우저 기반 PDA·관리 화면, Ollama systemd
저장	로컬 SQLite, 미전송 기록 관리, Aiven MySQL 인계·질의 업로드
지식 데이터	지식카드 86장·원문 58개 문서·인계 기록 40조각. 최종 검색 색인 3,950조각, 768차원 벡터 행렬

2.1 원문 RAG 구축 과정

카드에 없는 매뉴얼·안전 지침까지 답변 근거로 활용하기 위해 원문 검색을 추가했다. 색인은 PC와 임대한 GPU에서 구축하고, Jetson은 조각 JSONL과 벡터 행렬을 읽어 질의 시점의 검색·판정·생성을 수행한다. 제조사 원문 PDF는 공개 저장소에 재배포하지 않고 외부 모델 API로 전송하지 않는다. R1

구분	구축 결과
원문	58개 문서 2,459쪽. 제조사·기술 문서 40개와 안전 지침·법령 18개. 정제 후 2,233쪽 사용
최종 색인	원문 3,824 + 카드 86 + 인계 기록 40 = 3,950조각. 영어 조각 2,900/3,950
청킹	쪽 경계를 넘지 않도록 700토큰 기준으로 나누고 같은 절 안에서는 60토큰 겹침. 카드 1장 = 1조각으로 보존
임베딩	`embeddinggemma` 300M (0.6GB), L2 정규화한 768차원 float32 벡터. Jetson 질문 임베딩은 CPU에서 수행
검색과 근거	설비·공통 폴더 필터를 적용한 dense 검색. 상위 30개 중 같은 문서·쪽의 중복을 제거해 최대 8조각·2,500토큰을 선택하고 인계 기록은 1개까지 포함
판정과 생성	판정기가 조각별 적합 확률 P(점수 ≥ 2)를 평가한 뒤 답변 모델(`ck176`)이 근거를 인용. MES 현재값·안전 카드·문서명과 쪽 번호를 함께 표시

추출과 검색 설정을 고른 근거

`pypdf`로 쪽별 텍스트를 추출하고 반복 머리말·목차·빈 쪽·중복 쪽을 정제했다. 카드 출처의 핵심 단어가 인용 쪽 전후 1쪽에 절반 이상 남은 경우는 84/93이었다. 청크 크기(250·450·700)와 임베딩 모델 4개를 비교해 700토큰을 채택했으며, 이후 근거 예산 확대와 인계 기록 상한 적용으로 개발 셋의 근거 안 정답이 86 → 99/123으로 늘었다.

`bge-m3`는 원문 쪽 검색 지표가 더 높았지만, 실제 생성 비교에서는 `embeddinggemma`의 정답 근거 포함이 86/123·정답 인용이 77/123으로 `bge-m3` 레인의 77/123·71/123보다 높고 모델 크기도 작았다. BM25와 재순위화는 주 검색에서 제외하고 별도 벡터 DB 대신 NumPy 행렬을 사용했다. 보류 셋의 근거 안 정답은 17/35로 낮아 검색의 일반화 한계가 남았다.

> **방법이 섞인 안전 지침 조각 수정**
> 10/22에는 KOSHA E-14의 서로 다른 응급조치 방법이 같은 조각에 섞인 문제를 발견해 방법 제목 기준으로 다시 나눴다. 색인은 3,951 → 3,950조각이 됐고 추적하던 잘못된 자세·조치 결합 오답이 사라졌다. 이 결과를 다른 지침의 안전성 검증까지 확대하지 않는다.

3 계획 대비 변경

항목	초기 계획	최종 반영	변경 이유
설비 입력	웹캠으로 설비 촬영	Unity 작업자 시점 영상을 PDA에서 한 장 촬영해 Pi CNN으로 분류	가상 공장 시연의 입력·촬영 환경을 통일
웹캠 역할	설비 인식 입력	PDA 얼굴 로그인 입력으로 분리	설비 촬영 경로와 사용자 확인 역할을 구분
지식 규모	사건 120건·카드 150건 등 대규모 생성	경량 MVP 중심으로 조정한 후 채택 카드 86장을 구성	일정 안에 카드의 작성·검수·검색 연결에 집중
응답 방식	카드 기반 생성·추출형과 hybrid	원문 검색·확률 판정 경로인 `S30h`, 이후 `C5-ck176` 구성	답변 범위 확대와 MES 현재값 반영. 거절·근거 품질의 약점은 별도 보고
CNN 최적화	FP32·INT8 비교	FP32 채택	INT8 정확도가 낮았고 Pi FP32 추론 지연은 사용 가능한 수준
지식 탐색	카드 목록·검색	게시 경로·참고 그래프 통합, 별도 운영 온톨로지 시제품	출처 확인과 상황·설비 관계·카드 연결을 구분해 확장

4 결과

구현 결과와 실제 실행 결과를 나누어 정리했다. 완료 여부는 각 시험의 입력·설정·시점에 한정하며, 모델이나 시연 구성이 달라진 결과를 동일 성능으로 합산하지 않았다.

평가 항목	결과	근거와 범위
지식카드 구성	달성	기존 KB 86장 보존. 채택 상태는 실제 현장 전문가의 검증 완료를 뜻하지 않음
설비 인식과 답변 연결	기존 구성에서 확인	10/8 HPU-01 촬영 → Pi 분류 설비 자동 선택 → Jetson 답변 K-1008 근거 기록
인계·클라우드 복구	기존 경로에서 달성	10/8 실제 Aiven DB 포트 차단·복구 시험. 인계·질의 기록 누락·중복 0건
최신 앱 배포	확인	10/22 Jetson·Pi 적용과 서비스 active 기록. KG explain은 해당 배포에 포함되지 않음
지식카드 게시	부분 검증	격리 DB 사본에서 게시·실제 임베딩 검색을 확인. 운영 후보 게시와 최종 답변 통과는 별도
지식그래프와 상황 인식	참고 그래프 구현·시제품 시험	기존 289노드·434관계 참고 그래프와 별도 운영 온톨로지 v0·상황 판정기를 시험. 운영 통합·독립 평가는 별도

4.1 모델 발전과 동일 조건 비교

Qwen2.5-3B에서 EXAONE-3.5-2.4B로 전환한 뒤 판정·답변을 분리했다. 카드 기반 E1 hybrid에서 원문 RAG(`S30h`), MES를 읽는 `ck176` 으로 확장했으며 최종 `C5` 에 코드 규칙과 조각 분할을 결합했다. R2

단계	변경 내용	선택 이유와 한계
범용 모델	Qwen 3B → EXAONE 2.4B	초기 20문항에서 인용 적중이 9 → 13으로 상승. 최종 평가 셋과 직접 비교하지 않음
E1-hybrid	SFT 판정기와 추출형 대체 가드 도입	카드 기반 근거 거절을 강화했지만 매뉴얼·인계 질문 범위가 제한됨
RAG v2-S30h	원문 검색· `ck106` 과 확률 판정 경로	보류 셋에서 답한 문항은 6 → 25/35로 증가. 답이 없을 때의 거절과 현재 상태 해석의 약점은 남음
ck176·ck186	MES 현재값·경보를 함께 읽도록 SFT	`ck176` 은 MES 반영이 개선됨. `ck186` 은 사전 기준인 현재값 ≥ 38/42·경보 ≥ 7/8·모순 0에 미달해 미채택
C5 최종	**`MES_ONLY` 해제, MES 상태 첫 줄 고정 표시, 관측값 없음(`UNOBSERVED`)·대상 설비 검증(`UNIT_GUARD`) 규칙, E-14 분할**	**지식 질문의 거절 품질과 설비 상태 표시를 함께 개선. 10/22 C5·분할 색인의 Jetson 적용 기록이 있음**

Jetson 321문항 공통 비교

10/21~22 공통 321문항은 S1 봉인(60)·S2 개발(201)·S3 MES 충돌(60)으로 구성했다. 올바른 행동률은 정답 근거로 답한 문항과 올바르게 거절한 문항의 비율이다. 실행 오류 0건은 정답률 100%를 뜻하지 않는다.

구성	S1 행동	S2 행동	현재값 / 42	경보 / 8	모순	p95 (초)
C1 hybrid	45%	61%	6	0	1	7.4
C2 RAG v2	52%	57%	0	0	3	7.7
C3 S30h	50%	63%	0	2	12	9.0
C4 ck176 + MES	48%	44%	42	8	0	10.4
C4b ck186 + MES	50%	52%	37	4	1	9.2
C5 최종	**48%**	**60%**	**30 (화면 42)**	**7**	**0**	**10.5**

> **결과 해석:** C5의 현재값은 모델 본문 답변에 반영한 경우(30/42)와 코드가 붙이는 MES 첫 줄의 화면 표시(42/42)로 구분한다. S1 내용 정답률(58~60%)은 동일 답변 모델을 쓰는 C4 계열(`C4c`) 기준 채점값이며 초기 모델인 C1(37%)보다 높았다. C5 최저 여유 메모리는 1,035MiB, p95는 10.5초로 기존 목표 10초를 넘었다. 추적한 4개 오류 유형의 0건을 전체 안전성 보장으로 해석하지 않는다.

4.2 구성 요소별 측정 결과

측정 항목	결과	측정 조건과 해석
CNN 정확도	875/880 (99.43%)	10/8 Unity 이미지 test 880장. train 7,178·val 893·test 880 사이의 그룹/해시 중복 0. 실제 설비에 대한 일반화 수치가 아님
CNN 클래스별	CAU 87/87, CV 173/176, GR 148/149, HPU 96/96, PDP 91/91, RT 280/281	클래스별 분모를 유지해 보고. FP32를 사용하고 INT8 두 구성은 미채택
Pi 추론 시간	41~63ms/장	Pi 4 CPU·ONNX Runtime 1.20.1·FP32. 클래스당 사진 1장, 총 6/6 정답. 촬영 이미지 디코드(G1)를 포함하면 57~82ms
저장 사진 E2E	17/20 성공, p95 7.08초	10/8 hybrid·FP32. p95는 질의에 도달한 17건 기준. 실시간 촬영 버튼·화면 확정 시간은 제외
클라우드 복구	복구 후 29초 업로드, 누락 0·중복 0	10/8 Aiven DB 포트 차단 시험. 복구 후 인계 4건·질의 201건의 고유 ID를 유지
S30h 기존 평가	test30 인용 4/11, 올바른 거절 11/19	10/16 `ck106` 계열 구성. hybrid 인용 3/11·거절 17/19와 비교. 현재 `ck176` 성능으로 사용하지 않음
C5 발전 지표	현재값 반영 30/42, 경보 7/8, p95 10.5초	10/21~22 Jetson 321문항 PR 기록. 화면 현재값 표시는 42/42. 일부 지표의 충족이 전체 품질의 통과를 뜻하지는 않음
배포 후 질의	HTTP 200, 8.81초	10/22 RT-02 압력 질의 1건. 카드 인용이 비어 있어 카드 기반 답변 성공으로 집계하지 않음

4.3 영역별 결과

유현준 | 팀장·시스템 통합

Unity-MES-PDA 연동, 인계·게시 경로 구현, 전체 시스템 운영·배포 및 지식그래프 통합

최재영 | AI·검색·모델 평가

원문 검색·판정·SFT 답변 파이프라인 구성, 모델 비교·평가 수행, Jetson 모델 운영

허재원 | 임베디드·장치·시연

엣지 장치 입력·추론·저장 경로 구현, PDA·CNN 관련 최적화 및 영상·장비 운영

전혜민 | PM·QA·발표

요구사항·일정·증거 관리, 평가셋 설계·검수, 최종 발표자료·대본·결과 보고서 정리

4.4 운영 온톨로지와 상황 인식 시제품

기존 `kg-demo-v1`은 카드·설비 분류·출처를 연결한 참고 탐색 그래프다. 별도 실험에서는 이를 보존한 채 MES 관측과 해석을 연결하는 운영 온톨로지 `v0`를 만들었다. 문서에 기록된 완료 범위는 그래프·상황 판정기 시제품과 합성 MES의 흐름 시험(`E0`)이며, 이후 독립 평가·PDA 알림은 후속 계획이다. R3

계층	연결한 개념	규모와 원칙
공장	설비 유형·개체·라인·부품·고장 모드	설비 10·부품 18·고장 모드 41. 설비 의존 관계의 방향·인과 여부·지연을 구분
관측	신호 종류·측정점·상태·증상 패턴·경보·대기 사유	신호 종류 48·측정점 69·증상 패턴 15. 정지 설비의 값을 운전 중 이상과 구분
해석	증상 개념·원인 후보·확인 항목·전파 규칙	원인 후보 30·확인 항목 30·전파 규칙 6. 원인은 확정 진단이 아닌 후보로 표시
지식	카드·문서 판본·적용 조건·조치 단계	카드 86·문서 판본 92·조치 단계 108. 안전 카드는 실행 조치가 아닌 게이트로 사용

그래프 `v0`는 765노드·1,153관계이며 기존 289노드·434관계 그래프를 포함한다. 패턴·경보-카드 링크 73개, 증상 연결 7개와 전파 규칙 6개는 제안 상태로 검수가 필요하다. 두 그래프의 규모를 같은 산출물의 전후 성능으로 비교하지 않는다.

합성 MES 흐름 시험 (E0)

판정기는 최근 3프레임의 측정값, 증상, 경보, 운전 상태·대기 사유만 읽고 시나리오 ID·고장 정답은 읽지 않는다. PDP-01 전류 50A 예제에서 하류 GR·HPU 부하 관계를 확인해 원인 후보·확인 항목·참고/안전 카드를 표시하고 직접 조치 카드의 공백도 표시했다. PC 기준 추가 시간은 틱당 2.8ms였다.

시험 구분	현재 MES 증상 판정	시제품 인식	엉뚱한 설비 지목	조치 카드 연결
이름 붙은 고장 11개	2/11	11/11	0	10/11
신호 하나 이상 69개	3/69	69/69	0	7/69

> **남은 검증과 실험 계획**
> 본 시험은 합성 MES의 경보와 제안 연결을 활용한 시험이다. 공유 패턴 표를 쓴 무작위 고장 317건의 인식률 93%·오탐 0건은 순환 평가이므로 독립 정확도로 쓰지 않는다. 카드 연결이 있는 경우는 6/15 패턴이다. 독립 정답·가림 시험·seed 동결과 PDA 알림·Jetson 지연·블라인드 평가(`E1~E4`)는 후속 계획이다.

5 문제 해결 과정

문제 현상	확인한 원인 또는 조건	적용한 해결과 결과
카드가 있어도 엉뚱한 근거로 답변	모델이 여러 후보 중 근거를 고르는 과정에서 오류가 발생	검색·판정·답변 역할을 나누고 초기에는 상위 카드 중심 입력과 추출형 대체를 적용. 이후 원문 검색 기반 `S30h`로 확장
근거가 없는 질문에도 답변	관련성이 약한 조각이 통과하거나 높은 확률 경로에서 답변을 강제	SFT 판정기·확률 임계값·거절 경로를 적용. test30에서 거절이 약해진 결과는 한계로 보고
질문 설비와 다른 설비의 현재값 혼입	선택 설비와 질문에 적힌 설비가 불일치	설비 코드·위치·이름을 확인하는 `UNIT_GUARD` 등 코드 규칙 추가. C4g 비교에서 다른 설비를 언급한 경우 18 → 0건으로 감소. 별칭 인식 한계는 남음
유효한 관측값이 없어도 정상이라고 설명	질문한 센서의 값이 없는데 다른 신호를 근거로 사용	`UNOBSERVED` 규칙과 값 없음 문구 추가. 관측값 없는 신호의 일반 지식 질문까지 고정 답으로 바뀔 수 있음
INT8 CNN이 특정 클래스에 편향	INT8 시험 정확도가 0.141·0.113으로 낮아짐	정확도 0.994의 FP32를 채택. Pi 지연이 충분해 양자화를 사용하지 않음. INT8 저하 원인은 미조사
넓은 장면에서 설비를 잘못 확정	여러 설비가 함께 보이는 화면에서 CAU 0.90 판정	프레임 자동 분류 대신 사용자가 촬영한 한 장을 분류. 확신도가 낮으면 재촬영으로 안내
연결 장애 중 기록 전달	클라우드 접속 실패 중에도 로컬 인계·질의의 보존이 필요	로컬 대기 기록과 업로더 재시도·ID 중복 방지를 적용. 실제 DB 포트 차단·복구 대사에서 누락·중복 0건 확인
참고 연결이 답변 근거로 오인될 위험	그래프에는 검수 전 증상 후보와 판본 정보가 함께 존재	최종 인용과 참고 탐색을 구분. 판본 없는 인용 42건은 보류하고 2-hop 경로·표시 범위를 제한

> **통합 엔지니어링 접근 원칙**
> 위 문제 해결 과정에서 단일 모델 교체만으로 문제를 해결했다고 해석하지 않았다. 검색 입력, 판정 기준, 화면 표시, 장치 설정과 기록 경로를 함께 조정했으며 변경마다 실제 검증 범위를 엄격히 구분했다.

6 한계

1. 가상 공장과 합성 데이터의 한계

설비 사진과 센서·사건 데이터는 교육용 가상 공장과 합성 환경을 대상으로 한다. CNN 99.43%는 Unity 사진 시험 결과이며 실제 설비·조명·카메라·배치가 달라졌을 때의 정확도를 보장하지 않는다. 지식카드의 `accepted/L1` 상태도 실제 현장 전문가 승인과 같지 않다.

2. 답변 품질과 근거 적합성

`S30h`는 답변 범위를 늘렸지만 답 없는 질문의 거절이 약해질 수 있다. 10/16 test30에서 올바른 거절은 11/19로, hybrid(17/19)보다 낮았다. 이후 C5에서도 현재값 반영 30/42·경보 7/8 등 미충족 사례가 남았다. 센서값 표시와 근거를 갖춘 답변 성공은 구분해야 한다.

3. 전체 흐름 측정의 범위

저장 사진 20건의 시험은 17건 성공했고 p95는 질의에 도달한 17건 기준이다. 실시간 촬영 버튼과 PDA 화면 확정 시간이 빠져 있다. 기존 hybrid 구성의 시험 결과를 현재 `C5-ck176` 전체 흐름의 재검증으로 대체할 수 없다.

4. 코드 규칙과 운영 설정

질문에 명시적인 설비 코드나 위치가 없으면 "3호기" 같은 별칭을 놓칠 수 있다. 값 없음 규칙은 일반 지식 질문도 차단할 수 있다. 규칙과 검색 색인의 병합·교체·활성화는 서로 다른 절차이므로 최종 장치 설정을 확인해야 한다.

5. 게시와 클라우드의 검증 경계

기존 인계·질의 업로드와 실제 복구 대사는 확인했지만, 신규 조치 세션에서 나온 일지의 중앙 업로드 보류를 해제하는 일은 별도다. 게시 검색은 격리 DB 사본에서 확인했으며 운영 후보 게시와 게시 후 최종 판정·답변 생성까지의 통과를 뜻하지 않는다.

6. 운영 온톨로지와 실장비 검증

기존 참고 그래프와 별도 운영 온톨로지 시제품을 구분해야 한다. 시제품의 합성 MES 흐름 시험은 실제 고장 진단 정확도·GraphRAG·검색 성능 향상을 입증한 것은 아니다. 제안 링크 검수와 순환 없는 평가, PDA 알림·Jetson 지연, 10/22 배포 문서의 물리 입력·운영 롤백·KG explain 적용 범위는 별도로 확인한다.

7 개선 방향

개선 과제	추진 내용 및 검증 방법
실제 환경의 인식 성능 검증	촬영 거리·각도·조명·설비 배치를 바꾼 별도 데이터로 평가한다. 클래스별 오분류와 낮은 확신도 사례를 수집하고 실시간 촬영부터 PDA 표시까지의 성공률과 지연을 측정한다.
답변의 근거와 거절 품질 개선	검색과 판정에서 설비·증상·적용 조건이 맞는지 더 엄격히 확인한다. 값 없음·다른 설비·조건 불일치 질문을 분리해 평가하고 답변율·인용 정답·올바른 거절을 함께 보고한다.
최종 운영 구성의 재현성 확보	시연 코드·모델·색인·옵션을 하나의 버전표로 관리한다. 장치 재부팅, 서비스 예열, 첫 질의, 네트워크 복구와 백업·롤백을 같은 구성으로 재현해 기록한다.
조치 경험의 지식화 경로 완성	조치·근무일지의 로컬 저장과 중앙 업로드, 후보 검토·검수·게시를 연결해 검증한다. 게시된 카드가 검색되고 적절한 근거로 답변되는 단계까지 확인한다.
온톨로지의 독립 평가와 알림 연결	제안 링크·전파 규칙을 사람이 검수하고 독립 정답과 가림 시나리오로 상황 인식·원인 위치·카드 연결을 평가한다. 기본으로 꺼져 있는 PDA 알림 시제품, Jetson 추가 지연과 블라인드 유용성 평가는 후속 단계로 수행한다.

프로젝트 링크와 결과 근거 문서

- **[R1]** 원문 RAG 구축 과정 (2026년 10월 23일)
- **[R2]** 모델 발전 보고서 (2026년 10월 22일)
- **[R3]** 운영 온톨로지와 상황 인식 실험 계획 (2026년 10월 22일)
- **Notion 워크스페이스:** https://www.notion.so/3ecb7d115dd1809fafb8fe32a307b3e7
- **세부 검증 기록 (Notion 하위 문서):** 설비 분류 CNN 결과와 클래스별 표본 / 촬영 한 흐름 및 저장 사진 20건 시험 / 클라우드 연결 차단과 복구 결과 / 10월 22일 Jetson과 Pi 배포 결과 / 지식그래프 통합·범위·검증